

卒業論文 2020 年度 (令和 2 年度)

Depth2Jam: ドライブレコーダーを用いた渋滞推定システム

指導教員

慶應義塾大学環境情報学部

村井 純

楠本 博之

中村 修

高沢 一紀

Rodney D. Van Meter III

植原 啓介

三次 仁

中澤 仁

武田 圭史

慶應義塾大学 環境情報学部

李 広耀

koyo@ht.sfc.keio.ac.jp

卒業論文要旨 2020 年度 (令和 2 年度)

Depth2Jam: ドライブレコーダーを用いた渋滞推定システム

論文要旨

日本において渋滞情報は主に道路に設置されているセンサーや監視カメラの映像から、逐次 VICS などの交通情報管理センターへ送られ、そこから自動車のナビゲーションシステム等に送信している。しかし、現状渋滞情報を取得できるのは高速道路や国道などの一部の道路に限られており、そうでない道路では渋滞情報を収集できない。また、ドライブレコーダーは近年の性能向上や危険運転や煽り運転の表面化の結果搭載率が高まっている。しかし、搭載されたドライブレコーダーの映像を見るなどの活用をされるケースは少ない。ドライブレコーダーは映像デバイスであるため物体検知や画像認識を行うことできさまざまなデータを収集することが可能である。本研究の目的は限られている渋滞情報が収集できるエリアを減らし、ドライブレコーダーの新しい活用方法を提案することである。目的に対するアプローチとして、ドライブレコーダーの映像から渋滞推定を行うシステム Depth2Jam を提案する。本研究では Depth2Jam を実装し、渋滞推定精度について実験評価を行った。また、Depth2Jam の精度について精度向上のための改善点と今後の展望について示した。

キーワード

ドライブレコーダー、渋滞、深層学習、画像処理

慶應義塾大学 環境情報学部

李 広耀

Abstract of Bachelor's Thesis Academic Year 2020

Depth2Jam : Congestion Estimation System Using a Drive Recorder

Abstract

In Japan, traffic jam information is mainly obtained from sensors and monitoring cameras installed on roads, and sent to traffic information management centers such as VICS, which in turn send the information to car navigation systems. However, traffic jam information can currently be obtained only on some roads, such as expressways and national ways, and cannot be collected on other roads. In addition, the installation rate of drive recorders has been increasing as a result of recent improvements in performance and the surfacing of dangerous and incendiary driving. However, there are few cases in which the videos from the installed drive recorders are used for viewing. Since the drive recorder is a video device, it can collect various data by detecting objects and recognizing images. The purpose of this research is to propose a new way to use the drive recorder and reducing the area where traffic jam information can be collected, which is limited. As an approach to the purpose, we propose Depth2Jam, a system to estimate traffic jam from the images of drive recorders. In this study, we implemented Depth2Jam and conducted an experimental evaluation of the accuracy of traffic jam estimation. In addition, we show the improvement of the accuracy of Depth2Jam and its future prospects.

Keywords

Drive Recorder, Traffic Jam, Deep Learning, Image Processing

**Keio University Faculty of Environment and Infomation Studies.
Koyo Ri**

目次

第 1 章	はじめに	1
1.1	背景	1
1.1.1	渋滞について	1
1.1.2	ドライブレコーダーについて	2
1.2	問題	2
1.3	目的	3
1.4	渋滞の定義	3
1.5	構成	3
第 2 章	渋滞とドライブレコーダー	4
2.1	渋滞の原因	4
2.2	渋滞がもたらす影響	5
2.3	渋滞検知	6
2.3.1	プローブ情報	7
2.3.2	GPS 等の位置情報	8
2.4	ドライブレコーダー	9
2.5	ドライブレコーダーの可能性と機会損失	9
2.6	まとめ	11
第 3 章	関連研究	12
3.1	ドライブレコーダーを用いた研究	12
3.2	ドライブレコーダー以外の車載カメラを用いた研究について	12
3.3	渋滞推定の研究について	13
3.4	カメラを用いた距離推定の研究	13
3.5	物体検出システムについて	15
3.6	まとめ	16
第 4 章	アプローチ	17
4.1	設計	17
4.2	実装	18
4.2.1	ネットワークアーキテクチャ	18
4.2.2	距離推定と深度推定ライブラリ	18
4.2.3	自動車検出	18

4.3	渋滞の判断基準	19
4.4	予備実験 1 - 深度推定システム	20
4.4.1	実験内容	20
4.4.2	評価と使用するライブラリの決定	20
4.5	予備実験 2 - 動画への適用	23
4.5.1	実験内容	23
4.5.2	症例	23
4.5.3	解決アプローチ	24
4.6	予備実験 3 - 評価方法の決定	26
4.6.1	実験内容	26
4.6.2	使用するデータ	26
4.6.3	実験方法	26
4.6.4	評価基準の作成	27
4.7	ドライブレコーダー映像を用いた予備実験	28
4.7.1	実験内容	28
4.7.2	使用したデータセット	28
4.8	実験結果と課題	28
4.8.1	解決アプローチ	29
4.9	改良したシステムを用いた実験	30
4.10	実験結果	30
4.11	まとめ	30
第 5 章	実験	31
5.1	実験 1 - さまざまな状況における Depth2Jam の推定精度実験	31
5.2	実験 2 - Depth2Jam の精度評価実験	31
5.2.1	使用したデータセット	31
5.3	実験結果	32
5.4	評価	33
第 6 章	考察	34
6.1	精度の考察	34
6.1.1	誤検出	34
6.1.2	FN に関する考察	35
第 7 章	結論	37
7.1	今後の展望	37
7.1.1	処理時間の問題	37
7.1.2	容量の問題	37
7.2	本研究のまとめ	38
参考文献		40

図目次

2.1	VICS の仕組み (https://www.vics.or.jp/know/about/center.html)	6
2.2	実証実験中のプローブ情報を利用したシステム (https://response.jp/article/2020/03/05/332331.html)	7
2.3	ドライブレコーダーの記録を活用したことがあるかについてのアンケート結果 (年代別)[1] . . .	10
2.4	ドライブレコーダーの記録を活用したことがあるかについてのアンケート結果 (ブロック別) [1]	10
3.1	struct2depth と他の研究の比較 [2]	14
3.2	struct2depth のアプローチ (https://sites.google.com/view/struct2depth)	14
3.3	YOLO の物体検出システム [3]	15
3.4	YOLO のネットワーク構成図 [3]	15
4.1	ネットワークアーキテクチャ	18
4.2	元の画像データ	20
4.3	FCRN-DepthPrediction を用いたもの	21
4.4	struct2depth を用いたもの	21
4.5	症例 1 - 誤った検出	24
4.6	症例 2 - 自動車を検出できなかった症例	24
4.7	症例 1 の解決	25
4.8	症例 2 の解決	25
4.9	車間距離 4m	26
4.10	車間距離 5m	26
4.11	車間距離 6m	26
4.12	車間距離 4m 時の平均値	27
4.13	車間距離 5m 時の平均値	27
4.14	車間距離 6m 時の平均値	27
4.15	車間距離 4m 時の最大値	27
4.16	車間距離 5m 時の最大値	27
4.17	車間距離 6m 時の最大値	27
4.18	結果 1	28
4.19	結果 2	28
4.20	結果 3	28
4.21	結果 1	30

4.22	結果 2	30
4.23	結果 3	30
6.1	誤検出の例 1	35
6.2	誤検出の例 2	35
6.3	FN の例 1	36
6.4	FN の例 2	36

表目次

2.1	ドライブレコーダー導入の目的 (年代別)	9
2.2	ドライブレコーダー導入の目的 (地域別)	9
2.3	ドライブレコーダーの活用状況	10
4.1	距離別の平均値と最大値	27
4.2	使用したデータセット	28
4.3	実験 2 - 結果	30
5.1	実験 データセット	32
5.2	実験 1 - 結果	32
5.3	実験 2 結果	32
5.4	(参考) 画面全体を検出した場合の精度	32

第1章

はじめに

本章では、本研究における背景とその目的等について述べる。

1.1 背景

1.1.1 渋滞について

日本はアメリカや中国などの道路と比較して国土が狭く、人口密度が高い。それに伴って車道が狭く、渋滞が起こりやすくなっている。日々テレビやラジオのニュースで渋滞情報が報道されている。渋滞の問題として、交通が滞ることによる物資や人員の運送の遅れだけでなく、ドライバーへの肉体的、精神的悪影響が挙げられる。そのような背景のもと、ドライバーには渋滞情報をいち早く取得し、可能な限り渋滞を避けた運転をすることが求められている。

日本では、渋滞情報は、VICS 等の企業が道路に設置されているセンサーや車道付近に置かれているカメラの映像、および自動車に搭載されているセンサーや GPS の情報などをもとに算出されている。また、日本におけるカーナビゲーションシステムは VICS[4] 等の渋滞情報を元に到着予想時刻などを割り出している。VICS では車両感知器 (Vehicle Detectors) と光学式車両感知器の 2 つが主に使われ、それぞれ通過車両台数や渋滞情報を自動的に感知し交通管制センターへ送信する役割と、通過車両を感知するとともに車載装置との双方向の通信を行う役割を持っている。加えて、渋滞情報は Google 社が提供している Google Map にも提供されており、Web 上でリアルタイムのデーターを閲覧することが可能である。しかし、VICS 等が管理している渋滞情報は、国道や高速道路といった日常的に交通量が多い道路には設置されているが、そうではない細い道や一方通行といった道では渋滞情報がない。

日本以外の渋滞情報について、平成 13 年の警視庁によるトライフィック・インフォメーション・コンソーシアムでは、イギリス、ドイツ、アメリカの交通情報ビジネスについて述べられている [5]。まずイギリスの交通情報ビジネスに関しては、Trafficmaster という企業が道路光津法の規定に基づき国からの免許を得て、さまざまな形で事業を展開している。Trafficmaster の事業はイギリスだけにとどまらずドイツ、フランス、イタリア、オランダ、ベルギー等に及んでいる。Trafficmaster は道路上に情報収集装置を設置し、赤外線センサーやカメラによって車両情報を読み取っている。道路に情報収集装置を設置する点では日本における交通情報の取得と共通点がある。次にドイツの交通情報ビジネスに関して、ドイツは高速道路網が発達しており、ダイムラー・クライスラーの子会社とドイツ・テレコムの共同出資によって設立された Tegaron や、イギリスのボーダフォングループに属する Vodafone Tele Commerce によって交通情報ビジネスが行われている。また、この両社が共同

出資した DDG という企業は全国の高速道路に自ら設置した情報収集装置のほか、協力企業等の車両、警察や道路管理者等からの情報を統合し、上記の 2 社に情報提供を行なっている。そしてアメリカでは、複数の民間事業者が道路交通情報ビジネスを行なっており、特に Smart Route Systems という企業は全米 21 の大都市圏で事業を展開している。日本を含めて、これら 3 カ国の道路交通情報の取得に関して共通しているのはどれも道路に情報収集装置を設置しているという点である。

1.1.2 ドライブレコーダーについて

近年、煽り運転等のマナーの悪い運転が報道されるようになり、伴って各自動車へのドライブレコーダー搭載数が年々上昇している。^[6]マイボイスコム^[7]の調査によると、2020 年の統計において「所有している自動車の走行状況や駐車時の映像・音声を記録している機器」(複数回答)という問い合わせに対し、自動車所有者のうちドライブレコーダーだと回答したのは 42.3% だった。この結果は 2017 年の調査時の 20% から大きく上昇している。ドライブレコーダーは走行中の記録を撮ることにより事故の時の証拠を残すことができると同時に、事故等の証拠にもなり、警視庁も交通安全の面で、ウェブサイトにおいて取り付けを推奨している。元々、煽り運転等の危険運転はドライブレコーダーが登場する前から発生していたが、近年社会問題として取り上げられているのはドライブレコーダーやスマートフォンなど、映像技術の向上により人々が気軽に高画質な映像を録画、記録することが可能になったからだと考えられる。加えて近年の SNS の普及により、一般の人でも容易に事故の動画を発信したりと、注意喚起を行うことが可能になった。結果、煽り運転のような危険運転が容易に可視化され、ドライブレコーダーや、スマートフォンで撮影した映像がニュースでも取り上げられるようになった。

一般的なドライブレコーダーは事故の記録等で使われている。しかし現状、ドライブレコーダーの搭載が増加しているにもかかわらず、そのほとんどの用途が事故等の、もしものための貯蔵となっている。国土交通省の統計によると、ドライブレコーダーを取り付けた人のうち、実際にレコーダーの映像を見直すといった活用をしているのは 2 割ほどという結果が出ている^[1]。ドライブレコーダーの映像からは先行車や道路の状態、歩行者など、さまざまなデータを取得することが可能であることを考えると、現状のドライブレコーダーを単純な映像記録装置として扱うのでは不十分であり、さまざまな機能をつけることで、より効果的、効率的に扱えるようになると言える。

1.2 問題

現状の渋滞及びドライブレコーダーに関する問題は以下の通りである。

- 観光地等・季節で混雑する道路での意図しない渋滞に巻き込まれる可能性
- ドライブレコーダーのデーターの機会損失

まず 1 つ目の問題である、「観光地等の季節で混雑する道路での愛しない渋滞に巻き込まれる可能性」について述べる。海水浴場付近の道路など、観光地付近の道路は特定の時期のみ混雑する。国土交通省の発表した観光地による渋滞対策^[8]によると、観光交通の 9 割は自家用車であり、また日本人観光客の約半数が「渋滞」「駐車場」「道案内」に不満があるというデーターがある。国土交通省はこれらの問題の対策のために公共交通の連携や観光地周辺の流入規制等に加えて、AI や IoT の活用を行っている^[9]が、年々増加する外国人観光客等の影響で依然として問題は残っている。

次に 2 つ目の問題である、「ドライブレコーダーのデーターの機会損失」について述べる。背景の項でも述べ

た通り、近年の悪質な煽り運転の表面化やドライブレコーダーの性能向上および事故等の備えのためにドライブレコーダーの搭載数が増えている。ドライブレコーダーの本来の使い道としては上記の煽り運転や事故等の証拠とのための備えであるが、ドライブレコーダーは映像デバイスということもあり物体検出システムを活用することが可能である。ドライブレコーダーを活用した研究の一つとして三上氏の家庭ゴミの袋を数える研究 [10] があり、また、JapanTaxi 株式会社はタクシーに取り付けられたドライブレコーダー映像から道路の状況を解析する取り組みをしている [11]。このように、ドライブレコーダーは新しい IoT デバイスとしてのポテンシャルを持っているものの実際にそのような活用をされている例はほとんどないという問題がある。

1.3 目的

本研究の目的は、ドライブレコーダーを新しい映像デバイスとして物体検出ソースとして活用することである。ドライブレコーダーを使用して渋滞を推定することで、既存の渋滞検知手法である VICS や Google Map、そして GPS の情報だけでは見ることができない道路の渋滞の現場を可視化することが可能である。加えて、VICS などの道路に設置された情報収集装置と異なり、ドライブレコーダーはどのような自動車でも追加で取り付けることが可能であり、ドライブレコーダーで渋滞推定を行うことができれば、日本に限らず世界中の道路で渋滞推定を行うことができる汎用性がある。既存の渋滞検知手法では主に日頃から交通量の多い場所での渋滞の検知を行っており、渋滞を避けた先の小道や日頃渋滞が少ない道路における渋滞を検知することができない問題がある。そのため、渋滞を避けた先で検知されていない渋滞に巻き込まれるという問題が発生する可能性がある。ドライブレコーダーでどの道でも渋滞を推定することができれば、このような問題を未然に防ぐことが期待できる。

1.4 渋滞の定義

渋滞についての研究を行うためには、まず渋滞とはどのような状態か定義する必要がある。

自動車保険会社 ZURICH によると、日本道路交通情報センター (JATIC) では、一般道路に関しては時速 10km 以下で走行している状態、高速道路では時速 40km 以下で走行している状態を渋滞と定義している。これに対し、NEXCO 東日本では、高速道路においては時速 40km 以下の低速走行や停止や発進を繰り返す車列が、1km 以上かつ 15 分以上継続した状態を渋滞と定義している [12]。

本研究では正確な速度をカメラ映像から割り出すことは不可能なため、それらの定義とは異なる独自の定義を使用する。

1.5 構成

本論文の構成は以下の通りである。2 章で本稿で述べた問題について深く述べ、3 章で問題にまつわる関連研究について述べる。4 章では本研究におけるアプローチとその設計と実装について述べる。そして 5 章で本研究で実装したシステムについて予備実験を行い、6 章で本実験について述べる。最後に 7 章で本実験について評価および考察を行い、8 章で本研究のまとめについて述べる。

第 2 章

渋滞とドライブレコーダー

ここでは本研究の主軸である渋滞とドライブレコーダーについて述べる。

2.1 渋滞の原因

まず、渋滞の原因について述べる。大手自動車保険会社のチューリッヒ保険会社によると、渋滞は大きく交通集中渋滞、工事渋滞、事故渋滞の3種類に分けられる[12]。まず、工事渋滞と事故渋滞については、それぞれ工事や事故により道路区間の一部が通行できなくなり、渋滞が発生するというものである。これら2つの渋滞は原因がはっきりしている。

しかし、交通集中渋滞に関しては一般的に原因があまり知れ渡っていない。日本の高速道路の管理を行っているNEXCO 東日本の調査によると、2018年に発生した渋滞のうち約73%が交通集中事故だった[13]。

また、交通集中渋滞が特に起きやすいとされている場所もあり、以下のようにになっている。

- 上り坂・サグ部
- 接続道路
- インターチェンジ
- トンネル

サグ部とは、下り坂から上り坂に変わる凹状の場所のことを指す。上り坂やサグ部では、無意識に速度が低下しがちである。先行車の速度が低下すると、後続車が先行車の速度低下を確認し、次々とブレーキを踏む。このようなメカニズムで渋滞がどんどん伸びてしまうのである。NEXCO 東日本の2018年の調査によると、高速道路にて発生した交通集中渋滞のうち66%がこのような上り坂・サグ部で発生している[13]。

接続道路とは、高速道路と一般道をつなぐ場所のことを指す。高速道路の本線から一般道に出る地点に信号がある場合、青信号の間に車が一般道に出切らず、これが本線まで伸びて渋滞が発生することがある[12]。

次にインターチェンジだが、接続道路と同じく、高速道路と一般道路との出入り口として設置されているインターチェンジの合流部は渋滞が多発するポイントである[12]。車両の流入に伴って、車線変更や速度を落とすといった自動車が多くなるため、後続車の速度も低下し渋滞となっている。

そして、トンネルに関して、トンネルの入り口は、急に暗くなり、圧迫感を感じることから、知らず知らずのうちにスピードを落として渋滞の原因になることがある[12]。

2.2 渋滞がもたらす影響

渋滞中のドライバーには肉体的ストレスと精神的ストレスの両方がかかっている。肉体的ストレスに関しては、運転中は長時間座ったままであり、狭い車内で体を伸ばすことができない、という問題が考えられる。仮に遠出していて長時間渋滞に巻き込まれてしまうと同じ姿勢のまま運転する必要がありエコノミー症候群が発症する恐れが考えられる。また、ドライバーの精神的ストレスに関して、東京農工大学大学院の佐藤氏 [14] は、渋滞中のドライバーの精神ストレスを以下のように述べている。

- 目的地に早く着きたいのに自分の意に反して進めない
- 進もうとしているのに横入りにより邪魔される
- 退屈する

また、自動車の交通渋滞はドライバーのみに影響を与えるのではない。東京農工大学大学院の佐藤氏によると、渋滞中の交通事故の発生率は通常の時よりも 8 倍高い [14]。特に追突事故に関しては、通常の時よりも 16 倍高い事故発生率となる。

交通事故の原因の多くがヒューマンエラーによるものだと考えれば、渋滞情報を事前に取得し、渋滞を回避することは、ドライバーにとっても交通安全の面においても重要な課題なことがわかる。

加えて、渋滞における損失について、2015 年度の国土交通省の発表によると、国内の交通渋滞による総損失時間は年間約 50 億時間にもなるという [15][16]。

2.3 渋滞検知

現在の渋滞は主要な道路にセンサーやカメラなどを取り付けてリアルタイムに渋滞情報を検知し管理している。渋滞情報の取得には一般財団法人道路交通情報通信システムセンター（VICS）が関わっている。VICSではVICSセンターが国土交通省、地方自治体および都道府県警察からの渋滞情報を集めて管理している。集められた渋滞情報はFM多重放送、電波ビーコン、光ビーコンといった道路に設置された通信機でVICS対応カーナビゲーションシステムに送信し、渋滞情報や目的地までの到着予想時刻としてドライバーが受け取っている。また、特に高速道路における渋滞情報の取得については、道路に2km間隔でトラフィックカウンターという計測器が埋め込まれており、通過する車の台数、大型車や小型車の区別、車の速度を計測している。トラフィックカウンターだけではなく、高速道路においては交通管理隊が常に巡回しており、渋滞を見つけると無線で交通管制センターへ連絡し、ドライバーへフィードバックしている（図2.1）。



図2.1 VICSの仕組み (<https://www.vics.or.jp/know/about/center.html>)

しかし現状、渋滞情報は高速道路や国道といった主要な道路のみの情報しか得られておらず、それ以外の比較的小さい道路では渋滞情報を取得することができない問題がある。例えば旅行シーズン中など、普段の走行量が少ない道路にて走行量が急に増えた際に、事前に渋滞情報を取得して迂回することが困難になる。特に、1車線のような小さい道路が急な渋滞になるケースのことが多く、一度渋滞にはまってしまうと迂回ルートを取ろうとしても抜け出すことが難しくなる。

また、VICS非対応のカーナビゲーションが存在することも問題の一つである。日本は世界的な自動車生産量を誇り、日本で走っている自動車はほとんどが国産車である。しかし、2019年度の統計によると、日本市場における輸入車のシェアは6%となっており、輸入車に載っている人口は一定数いることがわかる。輸入車に乗っている人はVICS対応のカーナビゲーションを購入する必要がある。また、日本で販売しているカーナビゲーションにもVICSに対応していない機種が存在する。

2.3.1 プローブ情報

2020年よりVICSは渋滞ゼロ社会を目指すためにプローブ情報を利用したサービスの実証実験を行なっている(図2.2)。プローブ情報とは、車一台一台の位置、速度、通過時刻等の走行軌跡データーを指す。プローブ情報を活用することでこれまでトラフィックカウンターがなかった場所でも渋滞情報を取得することを目指し、実証実験を行なっている。

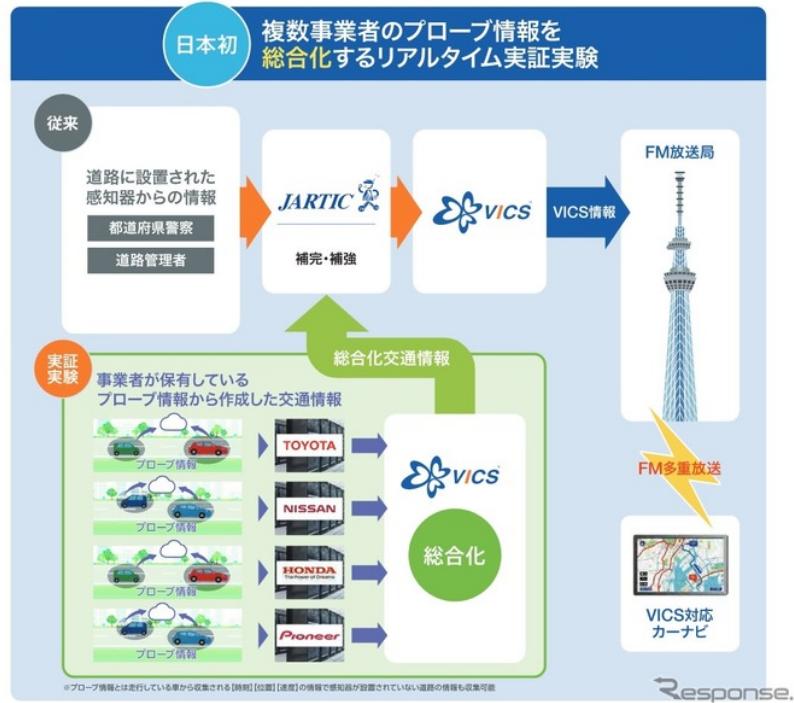


図2.2 実証実験中のプローブ情報を利用したシステム (<https://response.jp/article/2020/03/05/332331.html>)

しかし、プローブ情報には車のセンサーを主に使っているため、ドライブレコーダーを使う等の情報はない。センサーの情報のみを使って渋滞検知を行おうとすると、例えば低速運行しているのは渋滞に巻き込まれたからなのか、他の理由があるからなのか等の情報を得ることができない。また、車が停止したのは渋滞のためなのか、停止信号のためなのか、あるいは駐車のためなのかといった情報もセンサーからのみでは得ることができない。これらの情報を得るにあたって、ドライブレコーダーの使用は避けて通れないと考える。

加えて、本研究の実装するDepth2Jamのセンシングしたデーターをこのプローブ情報やVICSに送信することができれば新しい渋滞推定の軸として活用することが可能であると考えられる。

2.3.2 GPS 等の位置情報

VICS, プローブ情報に加えて GPS を用いた位置情報をを利用して自動車の交通量や渋滞等を検出する技術も存在する。GPS を用いた渋滞検知およびカーナビゲーションシステムのうち, よく使われるものとして”Google Map”が挙げられ, また日本では使用されることが少ないが, 欧米諸国等の海外ではよく使われる”Waze”[17] や”Sigyc”[18] というアプリが挙げられる。これらアプリの共通点として自動車の位置情報をスマートフォン等の GPS システムを搭載したデバイスを用いているという点である。また, GPS を利用しているため主にナビゲーションとして利用される側面が大きい。また, Google Map の位置情報サービスでは, GPS だけではなくインターネットの IP アドレス, 過去のデバイス使用履歴といった複数の要素でデバイスの現在位置を認識している.[19] これら GPS といった位置情報を利用しているアプリと比較して, ドライブレコーダーはレコーダーからの映像情報を活用できる点で差別化が可能である。加えて, GPS だけの利用だと, GPS を搭載したスマートフォン等のデバイスをたくさん積んだ手押し車で偽物の渋滞情報を作り出すことができる例がある.[20] 映像情報で確認ができるという点で GPS のみを利用するアプリと比較して信憑性が高いことがわかる。

2.4 ドライブレコーダー

次に、ドライブレコーダーについて述べる。2020年1月に国道交通省が出した統計 [1] によると、統計対象者のうちドライブレコーダーを実際に取り付けている割合は45.9%という結果が出た。つまり、統計の対象になったドライバーのうちおよそ半数がドライブレコーダーを搭載していることがわかる。また、同統計において、ドライブレコーダーの使用目的のアンケートがあり、以下のようにになっている。

ドライブレコーダーをなぜ導入するか(年代別) (複数回答可)	安全運転の意識を高める	自分の運転のクセなどを把握する	交通事故の記録	煽り運転等危険な運転への対策	綺麗な風景などの記録	その他
全年代	45.5%	10.2%	89.8%	71.7%	7.7%	5.2%
20代	50.0%	10.0%	90.0%	63.3%	16.7%	6.7%
30代	38.9%	13.0%	83.3%	74.1%	7.4%	13.0%
40代	46.1%	6.7%	92.1%	76.4%	11.2%	4.5%
50代	47.4%	5.3%	89.5%	59.2%	5.3%	5.9%
60代	42.1%	12.3%	93.0%	78.9%	3.5%	1.8%
70代以上	57.9%	31.6%	89.5%	84.2%	N/A	N/A

出典:「自動車用の映像記録型ドライブレコーダー装置について」(国土交通省)
(<https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>)

表 2.1 ドライブレコーダー導入の目的(年代別)

ドライブレコーダーをなぜ導入するか(地域別) (複数回答可)	安全運転の意識を高める	自分の運転のクセなどを把握する	交通事故の記録	煽り運転等危険な運転への対策	綺麗な風景などの記録	その他
北海道	43.5%	17.4%	91.3%	87.0%	4.3%	4.3%
東北	51.9%	11.1%	85.2%	74.1%	7.4%	3.7%
関東	44.4%	12.7%	82.5%	66.7%	7.9%	7.9%
北陸	63.0%	22.2%	85.2%	74.1%	7.4%	3.7%
中部	36.4%	9.1%	93.2%	77.3%	9.1%	6.8%
近畿	38.9%	1.9%	94.4%	70.4%	3.7%	3.7%
中国	39.3%	7.1%	89.3%	57.1%	17.9%	7.1%
四国	56.5%	17.4%	91.3%	69.6%	N/A	4.3%
九州	50.0%	2.8%	97.2%	75.0%	11.1%	2.8%

出典:「自動車用の映像記録型ドライブレコーダー装置について」(国土交通省)
(<https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>)

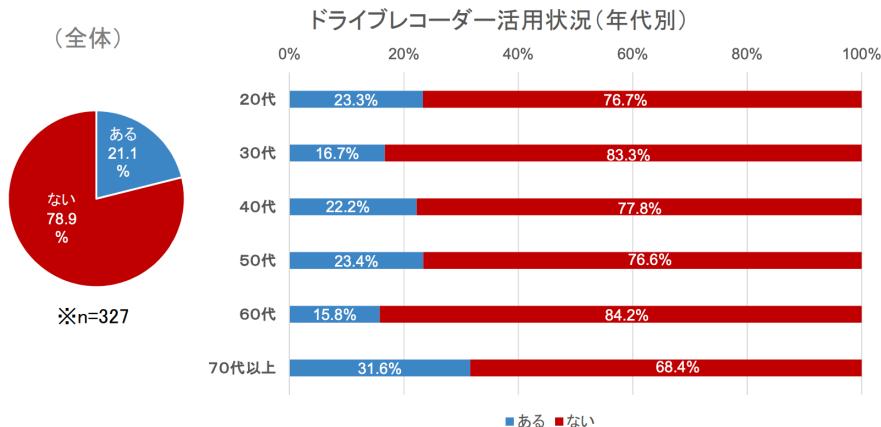
表 2.2 ドライブレコーダー導入の目的(地域別)

表から分かる通り、どの年代およびどの地域でも、ドライブレコーダーを取り付ける目的としては「交通事故の記録」が最も高く、次いで「煽り運転等危険な運転への対策」、「安全運転の意識」が高くなっている。また、同統計ではドライブレコーダーの活用状況についての統計があり、図??と図 2.4 に結果を示す。

また、ドライブレコーダーを実際にどのように活用したかについてのアンケート結果があり、表 2.3 に結果を示す。以上のことからわかることは、統計に参加したドライバーのうち約半数がドライブレコーダーを取り付けて入るもの、実際にドライブレコーダーの映像を活用できているのは全体の2割ほどであるということである。

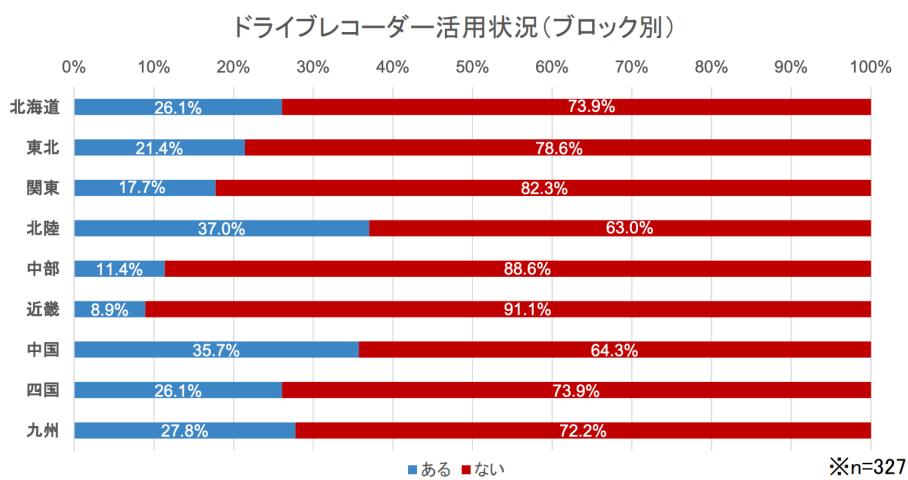
2.5 ドライブレコーダーの可能性と機会損失

2.2 章で述べた通り、ドライブレコーダーを設置している人口は一定数いるものの、そのほとんどがドライブレコーダー映像を見返すなどの活用をしていないことがわかる。本研究ではドライブレコーダーからの車間距離を推定することで渋滞を推定すること目的としているが、この車間距離の推定をすることでいざれは煽り



出典:「自動車用の映像記録型ドライブレコーダー装置について」(国土交通省)
(<https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>)

図 2.3 ドライブレコーダーの記録を活用したことがあるかについてのアンケート結果(年代別)[1]



出典:「自動車用の映像記録型ドライブレコーダー装置について」(国土交通省)
(<https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>)

図 2.4 ドライブレコーダーの記録を活用したことがあるかについてのアンケート結果(ブロック別)[1]

状況	ドライブレコーダーをどのように活用したか
交通事故の時	貴い事故の際に、自分の無過失が証明できた。 交通事故に遭遇した際に、第三者として記録を提出した。
安全運転のため	悪質な運転や犯罪の動画をもとに警察へ通報した。 事故になりかけた状況を、後日再確認した。 家族でお互いの運転を検証している。 車内での安全運転啓発に画像を利用した。 運転中に相手車の運転を確認する。 危険運転などの動画をSNSに投稿した。
その他	豪雨災害や隕石の落下などたまたま映っていた画像を共有した。 旅先などの景色や遭遇した野生動物などを録画した。

出典:「自動車用の映像記録型ドライブレコーダー装置について」(国土交通省)
(<https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>)

表 2.3 ドライブレコーダーの活用状況

運転の推定や警告などドライバーにとって有益な情報提供ができる研究に繋げることが可能だと考えられる。また、車間距離を推定することができれば、安全運転を評価することも可能になる。世界の情勢として、自動運転への移行に舵がとられているが、日本では法整備の問題等で完全な自動運転への移行は未だに時間がかかると予想されている。

加えて、ドライブレコーダーの映像から得られる情報は、ドライバーの見ている景色とほぼ同じだとすると、ドライブレコーダーを使って渋滞だけでは無く、道路標識や信号等も検出することが可能である。それらの検出をもとに、ドライバーがきちんと道路標識に従って、一時停止等していたか、十分な車間距離を守って走行できていたか、というようなドライバーが安全運転だったか否かを評価することができる。これは他のセンサー や GPS のデーターだけを用いる手法では難しく、ドライブレコーダーを活用する利点であると言える。さらに、先行車の動きをトラッキング、分析することで煽り運転の検出、警告することも可能である。1章の問題の項で述べた通り、ドライブレコーダーから得られる風景を物体検知システムを用いてさまざまなデーターを獲得することが可能なのに加えて、ドライブレコーダーを映像デバイスとしてより活用できれば運転中のドライバーへのフィードバックが可能になり、よりドライバーの安全運転を禹がなすことが可能であると考えられる。このようにドライブレコーダーを単なる映像記録装置のままで使用しているとさまざまな機会損失が発生してしまう。

2.6 まとめ

本章では渋滞とドライブレコーダーの諸問題について述べた。次章では本研究の関連研究について述べる。

第3章

関連研究

3.1 ドライブレコーダーを用いた研究

自動車にカメラ及びドライブレコーダーを取り付けて行なった研究として、まず道路のひび割れや塗装の剥がれといったものを検出する研究 [21] がある。画像処理技術が向上したこと、道路における障害物やひび割れといったものの検出が可能となった。しかし、道路のひび割れのような不動で固定的なものとは異なり、渋滞というものは時間と共に発生したり解消したり、また規模も大きくなったり小さくなったりと変化するものあり、変化するものに対しての画像認識の対応は困難なものだった。

ドライブレコーダーと機械学習を組み合わせたものとしては、Japan Taxi 株式会社が既にタクシーに高性能なドライブレコーダーをつけて、走行中の道路の状況等をリアルタイムに収集し解析するというサービスを行なっている。しかし、そこで行われているのは歩行者の検出や道路工事の検出などであり、発展して渋滞を推定すると言う旨の実現には至っていない。各タクシーから集められた情報をもとに人間の手で渋滞かどうか判断しているので、本研究によってその人間の判断を自動化する、あるいは事前に渋滞かどうか疑わしい現場の映像に判断材料を絞ることができる点で、本研究には貢献できる点があると言える。

3.2 ドライブレコーダー以外の車載カメラを用いた研究について

ドライブレコーダー以外の車載カメラの研究について、三上ら [10] は、ゴミ収集車にカメラを取り付けることで、ゴミ収集車にどれほどのゴミ袋が収集されたかを調べる研究を行った。ゴミ清掃車は、日々決まったルートを通り、決まった場所でゴミを収集している。その収集されるゴミの量を数値として可視化することで住民の生活の変化を可視化する研究である。自動車にカメラを取り付けて、映像情報からデーターを可視化するという目的の点で、可視化するデーターが異なるとはいえ、三上らの研究はこの研究と共通点がある。また、三上らの研究には私の研究と同様の YOLO と呼ばれる物体検出システムが使用されており、その物体検出システムが検出したゴミ袋の量を計測していた。

以上を踏まえると、物体検出システムを使用することでデーターの可視化が可能であると言える。

3.3 渋滞推定の研究について

ドライブレコーダー以外の方法でカメラから渋滞を測定する方法として, 進藤ら [22] は, 対向車の交通量を測定することで渋滞を推定する研究を行なった. 進藤らの方法は自動車 2 台を走行させ, その 2 台の横を通過した対向車の数から渋滞しているか否かを判断するものである. しかし, 進藤らの方法では測定するための自動車は常に道路の右側車線を走行しなければならないと同時に, 対向車道がない道路では渋滞を推定することができないという問題がある.

3.4 カメラを用いた距離推定の研究

車間距離を推定するフェーズに関して, 動画から距離を推定する方法はいくつか存在する. まず最も簡単かつ確実な方法は複眼カメラと三角関数を利用した方法である. 同じ対象を移したときに 2 つの視点からそれぞれのカメラから対象の距離を測定する方法である. しかし, 本研究の対象はドライブレコーダーであり, 1 つの自動車に 2 つのドライブレコーダーを搭載することは現実的ではなく, 複眼のドライブレコーダーは一般的に搭載されていないためこの方法は利用できない. そのため, この研究では単眼カメラの映像から車間距離を推定する必要がある. 単眼カメラから物体との距離を推定する研究としては, カメラ情報に加えて各種距離センサーの情報を利用することで実現する方法が一般的であった.

しかし, 近年では Deep Learning 技術の向上により, 各種センサーといった教師データーのない, 純粹に画像のみでの距離推定プログラムが実現している. Zhou ら [23] はセンサー情報等の教師データーのないカメラ映像から奥行きを推定するシステムを開発した. Zhou らのシステムは, 車載動画等の連続的な画像の集まりであるデータセットを元に映像における視界の変化を元に奥行きを推定するものであった. Zhou らの研究以降, カメラ映像における奥行きの研究は, Zhou らの研究を元に性能向上がなされ, Yin ら [24] などによってアップデートがなされた.

中でも, Google の研究チームの Casser らが行なった研究である”Struct2Depth”[2] というシステムは上記の研究と比較して精度がより向上されている図 3.1.

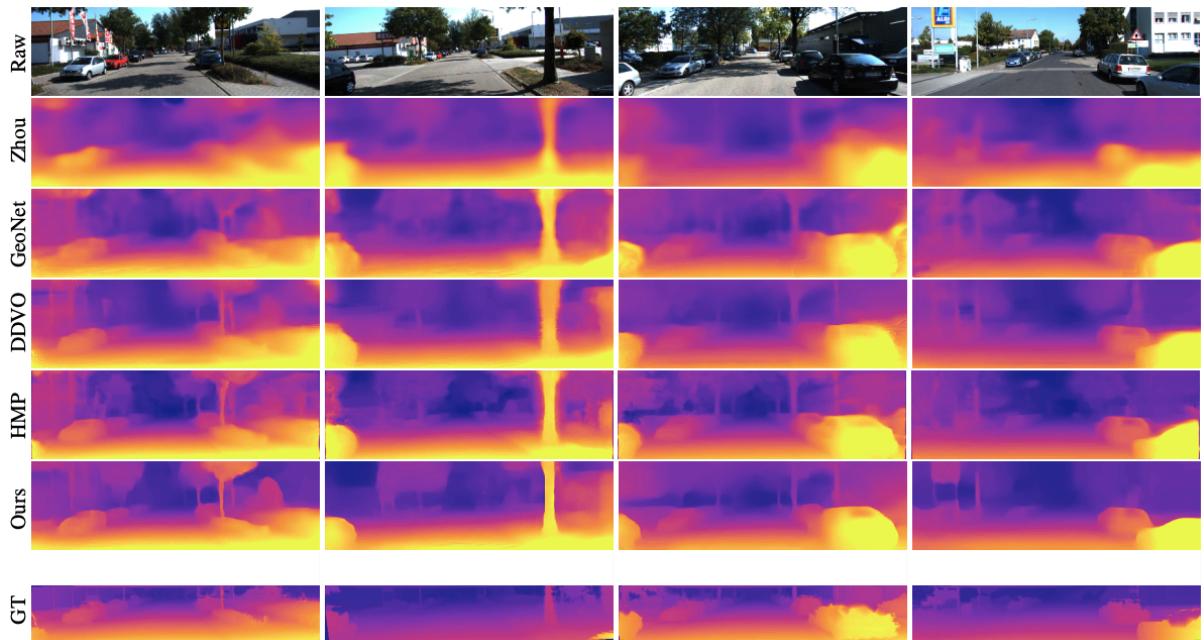


図 3.1 struct2depth と他の研究の比較 [2]

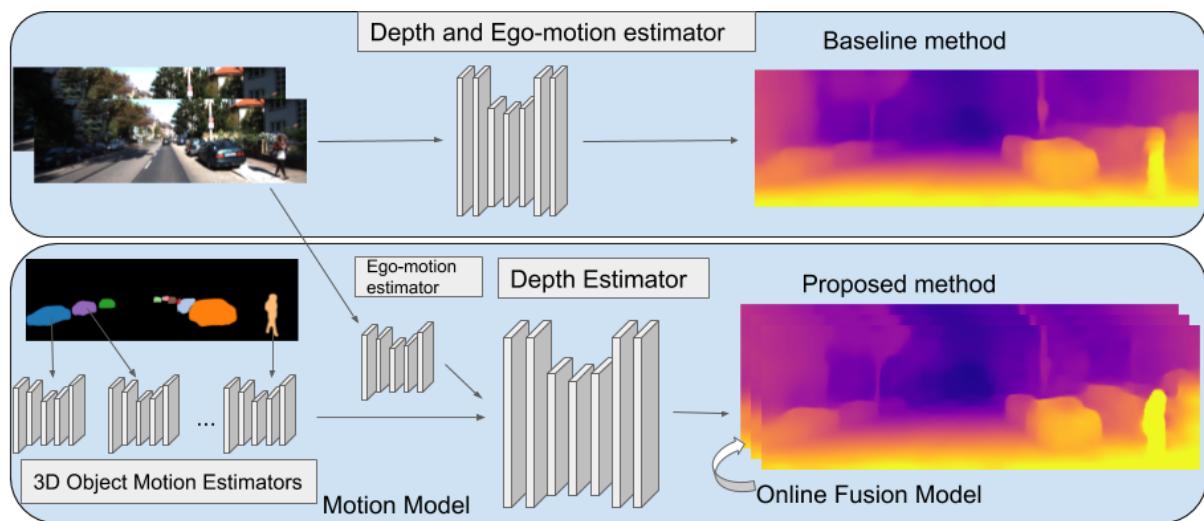


図 3.2 struct2depth のアプローチ (<https://sites.google.com/view/struct2depth>)

3.5 物体検出システムについて

物体検出を行うライブラリは様々あり,Fast R-CNNs[25],Mask R-CNN[26],SSD[27] といった手法が挙げられる。それぞれ CNN と呼ばれる畳み込みネットワークを利用し物体検出を行なっている点は同じだが,CNN の層や物体検出を行う際の手法がわずかながらに異なっている。本研究では物体検出手法として YOLO(You Only Look Once)[3] 図 3.3 図 3.4 と呼ばれる物体検出手法を用いる。YOLO は上記の 3 つの手法と比較して畳み込みネットワークやニューラルネットワークがシンプルな構造になっているにもかかわらず、高い検出率を誇っている。また、構造が比較的シンプルなため演算処理にかかるスピードが速く、リアルタイムでの処理にも適している。本研究では、YOLO が Microsoft COCO dataset を機械学習したものを利用し、ドライブレコーダーに写っている自動車、トラック、バスを主に検出させ、距離推定及びその結果からシステムの評価を行う。

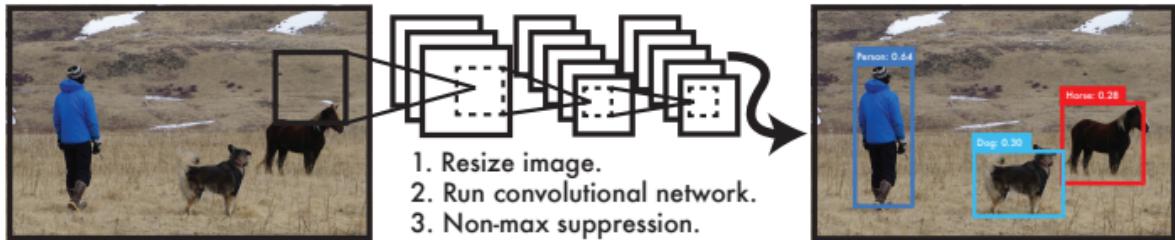


図 3.3 YOLO の物体検出システム [3]

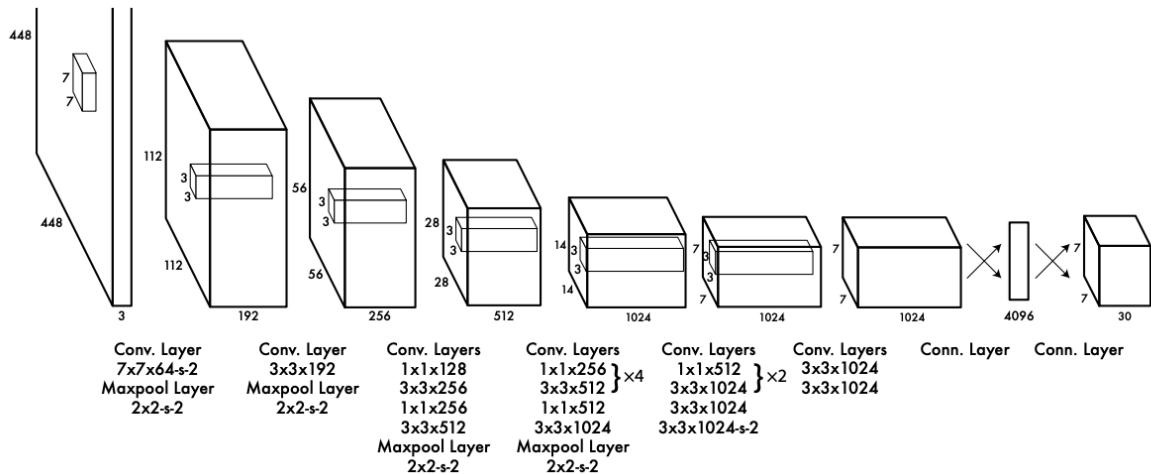


図 3.4 YOLO のネットワーク構成図 [3]

3.6 まとめ

本章では本研究における関連研究について述べた。次章では、問題に対する本研究のアプローチおよび本研究のシステムの実装と予備実験について述べる。

第4章

アプローチ

本研究ではドライブレコーダーの映像から自動車を検出, 車間距離を推定し, 渋滞しているか否かを判断するシステム Depth2Jam を提案する. 本章では, 自動車の検出と車間距離を推定する手法とそのネットワーク構造について述べる.

4.1 設計

本研究では, 汎用性を重視するためにドライブレコーダーから得られる情報のみを利用する. 渋滞の定義の項でも述べたが, 渋滞を推定するためには速度が重要だが, ドライブレコーダーと自動車の速度を同期させためには専用の取り付け工事が必要であり, また車の種類や自動車メーカーによって内部構造は異なっている. また, 映像から速度を推定する方法も手法の一つとして考えられるが, 映像から速度を出すためには相対距離の算出が必要であり, リアルタイムの情報が求められているこの研究では相対速度を計算する処理は処理時間を増やす原因を作ると同時に, 映像から正確な速度情報を算出することは非常に困難である. また, 速度センサーを搭載して速度を求める方法も考えられ, 加速度センサーの使用が考えられる. しかし, 現状加速度センサーが搭載されている市販のドライブレコーダーは存在しないため, 状況が限られてしまい, 汎用性が担保できない問題が発生する. また, 加速度センサーが搭載されているスマートフォンを自動車に取り付けて速度推定を行う方法も考えられる. 一般的に, 速度は加速度を積分することでその時々の速度を推定することができるが, 不良積分が多く発生してしまう恐れがあると同時に, 物体検出, 速度推定に加えてそのような加速度センサーデータから速度を計算すると機械が処理するものが多くなり, 映像の処理における FPS が低下する恐れがある. この FPS の低下はリアルタイムでの処理を目指すこの研究において重大な欠陥となってしまう.

さらに, GPS を用いて渋滞を推定する方法もあるが, ドライブレコーダー等の映像記録装置は実際に映像を取得できる利点があるのに対して, GPS は位置情報データーを取得するため, 得られる情報に限りがある. その上, GPS のみで渋滞情報を取得する方法は例えば GPS を搭載した電子機器を複数自動車に持ち込むと, 実際には渋滞していないのにもかかわらず, 渋滞していると出力してしまうような事例がある [出典] ため, 実際に渋滞の現場を確認することができると言う点でドライブレコーダーを使う方法が最も汎用性が高い. それに加えて, 速度だけで判断してしまうと, 例えば自動車が停止したとき, 渋滞のために停止したのか, 信号のために停止したのか, あるいは駐車したために停止したのか, 判断することができない, という問題が発生してしまう. 近年では自動運転技術等の向上により, 障害物に近づくとドライバーに警告するようなセンサーを搭載した高性能な自動車も存在するが, この研究ではより汎用性を重視するため, ドライブレコーダーの情報のみで渋滞の推定を行う.

4.2 実装

4.2.1 ネットワークアーキテクチャ

本研究はドライブレコーダーの映像から自動車を検出するフェーズと同じく映像から先行車との車間距離を推定するフェーズの2つのフェーズから構成されている。設計の項でも述べた通り、ドライブレコーダーにおける渋滞推定手法は物体検出システムと深度推定システムを用いる。本研究におけるネットワークアーキテクチャを図4.1に示す。

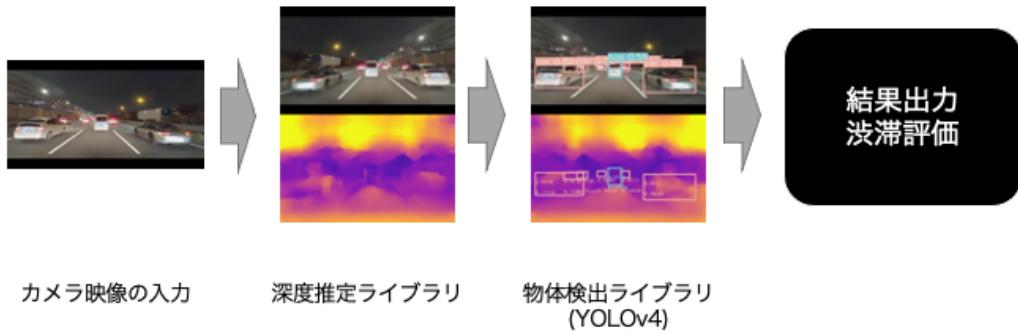


図 4.1 ネットワークアーキテクチャ

8

4.2.2 距離推定と深度推定ライブラリ

ドライブレコーダー映像から車間距離を推定する方法は深度推定ライブラリを利用する方法がある。本研究では深度推定ライブラリの中から FCRN-DepthPrediction[28] と struct2depth[2] の2つをピックアップした。どちらのライブラリも入力された映像から奥行きを推定し、カメラとの距離を色の明暗によって塗り分けがされる。本研究ではそのシステムを利用し、自動車が検出された BBOX の場所と同期させることでその明るさから先行車との車間距離を推定する。また、ピックアップした2つのライブラリのどちらかを使用するかについては実装と予備実験の項にて実験を行い、決定する。

4.2.3 自動車検出

自動車の検出には物体検出ライブラリを使用する。物体検出を行うライブラリは様々あり、Fast R-CNNs, Mask R-CNNs, SSD といった手法が挙げられる。それぞれ CNN と呼ばれる畳み込みネットワークを

利用し物体検出を行なっている点は同じだが、その CNN の層や物体検出を行う際の手法がわずかに異なっている。本研究では物体検出手法として YOLO(You Only Look Once) と呼ばれる物体検出手法を用いる。このシステムは物体を検出するとその物体を Bounding Box(BBOX) と呼ばれる四角形で囲むことでその物体の映像における位置を示すものである。YOLO は上記の 3 つの手法と比較して畳み込みネットワークやニューラルネットワークがシンプルな構造になっているにもかかわらず、高い検出率を誇っている。また、構造が比較的シンプルなため演算処理にかかるスピードが速く、リアルタイムでの処理にも適している。本研究では、YOLO が Microsoft COCO dataset を学習したものを利用する。

4.3 渋滞の判断基準

ここでは渋滞の評価方法について述べる。背景の項でも述べた通り、日本において渋滞の定義は自動車の運行スピードに依存しているが、本研究においては正確なスピードを取得するのは困難なため、先行車との車間距離を推定することで、その推定された距離を元に渋滞しているかどうかを判断する。

4.4 予備実験 1 - 深度推定システム

ここでは本研究を行うにあたり実装したシステムと予備実験および、その改善について述べる。

4.4.1 実験内容

本研究ではドライブレコーダーから得られる動画を用いて実験、評価を行うが、その予備実験として動画から切り出された画像を用いて本研究のシステムの実験を行った。この予備実験は、本研究を行うにあたって、距離推定プログラムあるいは深度推定プログラムの候補が2つあり、どちらが相応しいかを決める実験である。一つ目はFCRN-DepthPrediction[28]というシステムであり、もう一つはstruct2depth[2]である。元の画像および2つの深度推定ライブラリを使用した結果を図4.2、図4.3および図4.4に示す。



図4.2 元の画像データー

4.4.2 評価と使用するライブラリの決定

ここでは、本研究における予備実験の評価について述べる。図4.3と図4.4を比較すると、前者は深度推定を行なった結果のみを出力するのに対し、後者は元の画像を圧縮し上下二段二分けて出力されていることがわかる。また、前者は奥にある物体が明るく色分けされているが、カメラから近いところにある道路やトラックなど、ほぼ暗い青色で塗り分けられているだけであり、物体の識別が難しい。それに対して後者はカメラから近い距離にある物体ほど明るく塗り分けられており、奥にある物体ほど暗い色になっている。前者と後者を比較した際、特に違いが顕著なのは後者のシステムの方が画面左側にあるトラックをはっきりと色分けできているという点である。滋養の実験を踏まえて、本研究においては後者のGoogle Tensorflowを採用し、本実験を行うこととする。

また、図4.4を見ればわかる通り、物体検出システムと距離推定システムを用いることで先行車との大まかな車間距離を調べることが可能なことがわかる。図4.4における下段のBBOX内に出力されているパラメー

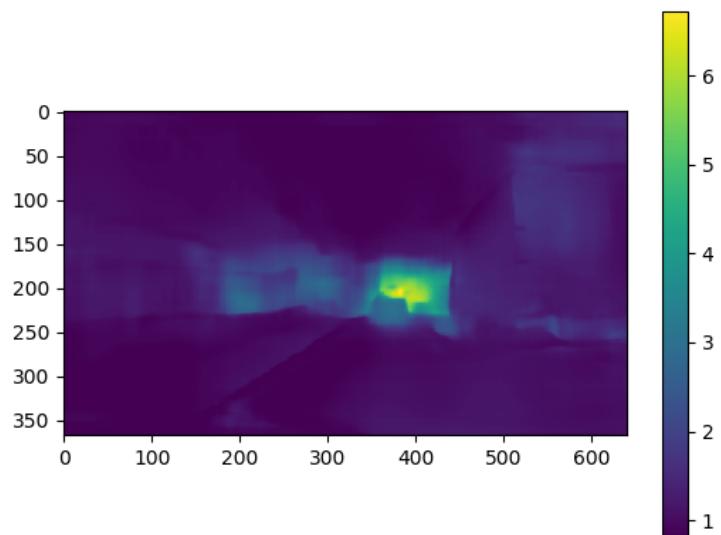


図 4.3 FCRN-DepthPrediction を用いたもの

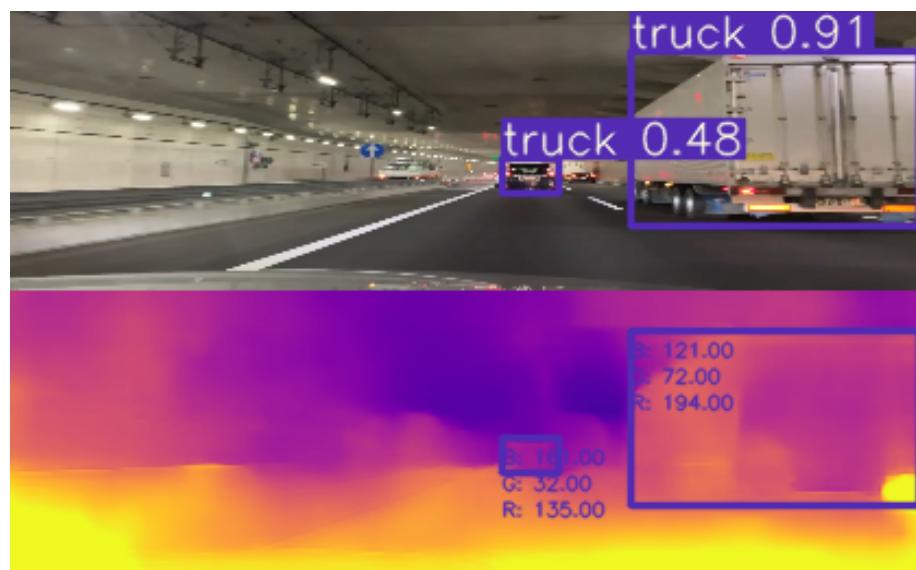


図 4.4 struct2depth を用いたもの

ターは、下段 BOX 内の RGB 値のそれぞれの値を平均した数値である。図 4.4においてシステムが検出した自動車をそれぞれ右から車 1, 車 2 とおくと、下段の RGB 値のそれぞれの平均を見てみると、奥にある車 1 の方が手前にある車 2 よりも R,G の値が低く,B の値が高いことがわかる。この数値の違いを評価することで先行車との距離を推定し、走行スピードを推定し、渋滞しているかどうかを機械に判断させる。

4.5 予備実験 2 - 動画への適用

ここでは 2 つめに行った予備実験について述べる。

4.5.1 実験内容

この予備実験は、予備実験 1 にて行ったシステムを動画へ適用する際に行なった実験である。予備実験 1 では使用した二つのライブラリ（物体検出ライブラリと深度推定ライブラリ）はどちらも画像のデーターを中間ファイルを通して処理していた。しかし、動画を使った画像処理をこなすためには、中間ファイルを経由しての処理は余分な処理を増やしてしまい、処理量と処理時間がかかってしまう問題がある。そのため、今後は中間ファイルを経由することなくデータをやり取りするように実行した。その際に、深度推定ライブラリ（struct2depth）に合わせて画像サイズを $416 * 128$ の高さの半分である $416 * 64$ サイズに圧縮して処理するよう実装した。しかし、画像サイズが圧縮されたため、物体検出ライブラリでの誤検出や検出できないといった問題が起きた。

4.5.2 症例

画像を圧縮してから検出を行った際に起きたミスとしては 2 つあり、それぞれ誤検出と検出できないという症例である。その検出結果を図 4.5 と図 4.6 に示す。

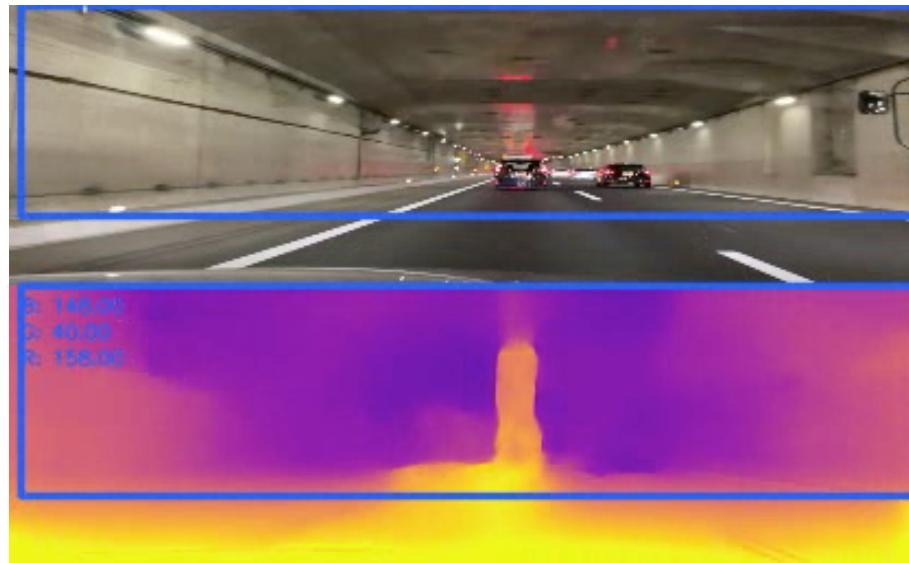


図 4.5 症例 1 - 誤った検出

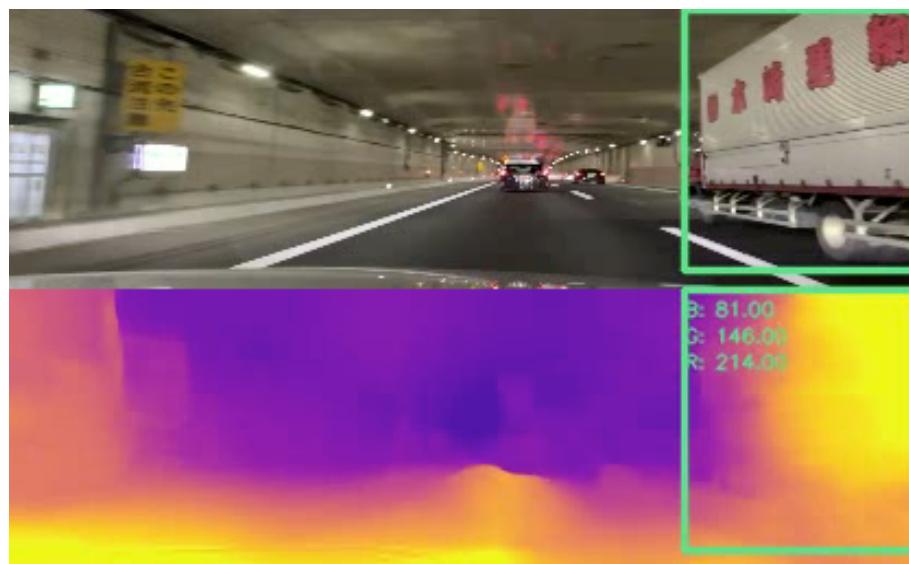


図 4.6 症例 2 - 自動車を検出できなかった症例

4.5.3 解決アプローチ

症例の原因は元の深度推定ライブラリに合わせて画像を圧縮したため、物体検出システムがうまく機能しなかったためだと考えられる。問題の解決のため、画像圧縮を避けて画像サイズを $416 * 256$ のまま処理できるように改良した。その結果、症例で見られるような誤検出や自動車を検出できないといった症例はほとんど見られなくなった。また、信号機や建物等、渋滞の推定のために必要なない物体を検出しないように、検出物体を自動車類（車、バス、トラック）に絞った。その実装したプログラムと同じ画像フレームを用いて実験した結果

を以下に示す。

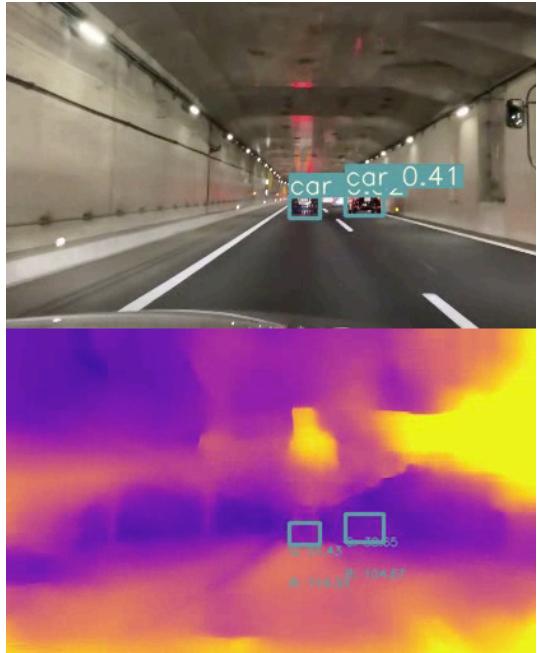


図 4.7 症例 1 の解決

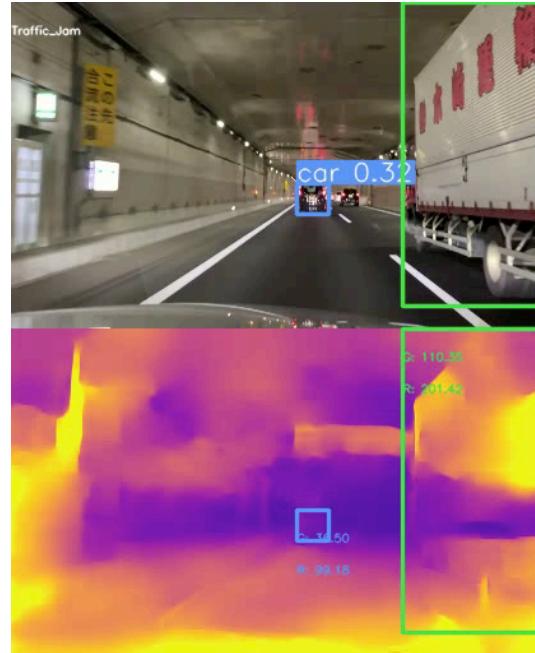


図 4.8 症例 2 の解決

図 4.5 と図 4.7, および図 4.6 と図 4.8 を比較すると, 画像の圧縮を抑えた分, 誤検出や検出できていない問題が大幅に改善できていることがわかる. この予備実験 2 の結果を踏まえて, 今後使用する映像圧縮サイズは 416 * 256 サイズとし, 最終的に出力されるサイズは strct2depth のデーターを加えた 416 * 512 サイズとする.

4.6 予備実験 3 - 評価方法の決定

ここでは 3 つめに行った予備実験について述べる。

4.6.1 実験内容

この予備実験は、本研究における渋滞の評価の基準を決める実験である。本研究にて使用する深度推定システム (struct2depth)[2] は奥行きを推定するシステムだが、図 4.4 の通り、結果は色情報でしかわからず、具体的にカメラからどれだけの距離があるのかが不明である。そのためこの予備実験 2 では渋滞評価のために出力された色データーから渋滞の基準を決める実験を行う。本研究では渋滞を車間距離を利用して推定する手法をとっているため、車間距離によって車のスピードや渋滞がどのように変化するかを参考にする。基本的に車間距離と速度の関係は一般道と高速道路で異なる。高速道路においては警視庁指示要項によると走行中の車間距離は「速度の 2 乗/100」をおおよそ安全追隨距離としている [29]。この場合、時速 80km で走っている場合、安全な車間距離は 64m となる。これに対して高速道路において渋滞している場合の速度は、渋滞の定義を参照すると安全な車間距離は最大で 16m となっている。しかし、一般道での車間距離は異なる。信号待ち等での停車中の車間距離はトヨタの web サイトによるとおよそ車一台分、4~5m とされている [30]。よってこの予備実験においては実際に車間距離が 4m, 5m, 6m の時に struct2depth における値がどのように変化するかを調べ、評価基準を決める。

4.6.2 使用するデーター

ここでは予備実験 2 にて扱うデーターについて述べる。この予備実験においては実際に車間距離を 4m, 5m, 6m のそれぞれにおいて運転席から撮影した映像を利用する。その際、自動車のフロントガラスにおいて様々な場所から撮影した。以下にサンプルを示す。



図 4.9 車間距離 4m



図 4.10 車間距離 5m



図 4.11 車間距離 6m

4.6.3 実験方法

ここでは予備実験 3 で行った実験方法について述べる。上記の項で示したサンプルデーターを struct2depth 及び Yolo システムを利用して、それぞれの距離において strct2depth の数値がどのように変わるかを調べた。その際、OpenCV の色情報取得システムを利用し、また検出された BOX の中において RGB 値それぞれの最大値と平均値を比較しどちらを利用すると良いかについても調べた。その結果の一部を以下に示す。



図 4.12 車間距離 4m 時の平均値



図 4.13 車間距離 5m 時の平均値



図 4.14 車間距離 6m 時の平均値



図 4.15 車間距離 4m 時の最大値



図 4.16 車間距離 5m 時の最大値

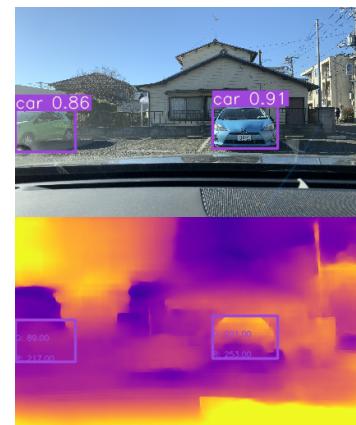


図 4.17 車間距離 6m 時の最大値

また、画像の中の R 値と G 値を改めて以下に表にまとめる。その際、まとめる数値は画面中央に近い自動車の検出された値とする。

	R 値	平均値		最大値		G 値	平均値	最大値
		R 値	G 値	R 值	G 値			
4m		226.75	253.00	203.00	129.54		203.00	
5m		213.53	249.00	153.00	110.19		153.00	
6m		201.77	253.00	201.00	97.33		201.00	

表 4.1 距離別の平均値と最大値

4.6.4 評価基準の作成

表 4.1 からわることは R 値は平均値と最大値のどちらにおいても距離との相関関係は薄いが、G 値の特に平均値は距離が近くなるにつれて値が大きくなる傾向があるということである。この実験結果をもとに、今後の実験においては G 値の平均値を用い、また予備実験 3 の実験内容の項で述べた通り、車間距離 5 m を基準とし、G 値が 100 を下回った際に渋滞していると判断する。

4.7 ドライブレコーダー映像を用いた予備実験

4.7.1 実験内容

作成された評価基準を用いて実際にドライブレコーダーにおいてどのようなパフォーマンスをするかの実験を行った。評価基準の通り, strct2depth 画面における車の bbox 内の G 値が 100 を超えた際に渋滞と判断し、画面左上に「Traffic Jam」という文字列が表示されるようにした。加えて、映像中に渋滞が判断された回数をフレームごとに Jam Counter として回数を映像中段左に表示するようにした。

4.7.2 使用したデータセット

本実験にて使用したデータセットは動画投稿サイト YouTube にて公開されていた高速道路を走行中の映像に加え、私の家族が使用している自家用車に取り付けられたドライブレコーダー映像を用いる。どの映像も 30 秒から 1 分のものであり、常に先行車がある映像を使用した。以下に使用した映像について表で示す。

映像番号	時間帯	撮影場所	車線数	動画時間
映像 1	昼間	一般道	1	60 秒
映像 2	昼間	一般道	2	60 秒
映像 3	不明	高速道路（トンネル）	2	60 秒

表 4.2 使用したデータセット

4.8 実験結果と課題

実験結果 1 ~ 3 に予備実験にて改良したシステムをそのまま用いると、様々な状況で渋滞を誤検出するという問題が発生してしまう。



図 4.18 結果 1

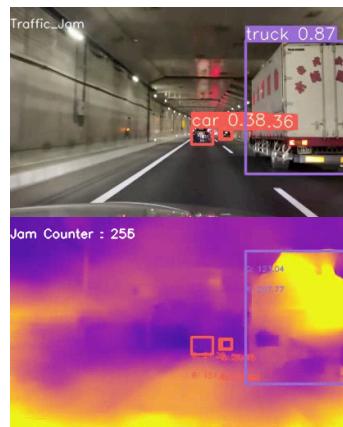


図 4.19 結果 2



図 4.20 結果 3

図 4.18, 図 4.19, および図 4.20 の結果からわかるように様々な要因で渋滞の誤検出が起きた。まず、図 4.18 においては対向車がドライブレコーダー付きの自動車を横切ってしまうとその際に渋滞と判断してしまう例で

ある。対向車の存在は渋滞と関係ないのに対し、渋滞と判断してしまうのは正しい判断ではない。次に、図 4.19においては、複数車線がある場合に隣の車線の自動車が近くで走行している際に渋滞だと判断している例である。先述の対向車のケースとは異なり、隣の車線の混雑は走行車線の混雑と関係がある。しかし、図 4.19のように、先行車との距離があるにもかかわらずたまたま隣で走っていたトラックが近いがために渋滞だと判断してしまうのは正しい判断ではない。そして、図 4.20においては、道路脇に駐車しているトラックを画像検知システムが検知てしまい、渋滞だと判断している例である。高速道路では稀であるが一般道を走行している際に道路脇に自動車が駐車されているのは珍しいことではなく、またその駐車は渋滞には一切関係がない。それでもかかわらず渋滞だと判断しているのは正しい判断ではない。これらの判断ミスのケースは表 4.3 の表にある映像のいずれにおいても頻繁に発生する問題であった。

4.8.1 解決アプローチ

実験 1 における問題の解決のために対向車、隣車線の自動車および駐車している自動車を検出しないという解決策を取った。対向車や隣車線の自動車といったものはドライブレコーダー映像において左右の 1/3 に写っている。ここに着目し、左右 1/3 に写っている自動車類の検出をしないように改良した。

4.9 改良したシステムを用いた実験

実験 1 における解決アプローチを元にプログラムを改良した。プログラムにおいて処理中の画像の横のサイズは 416 ピクセルなので、その 1/3 である 138 ピクセルの範囲で左右における自動車類を検出しないようにした。

4.10 実験結果

映像中における実験 1 と同じフレームの画像での実験結果を以下に示す。



図 4.21 結果 1



図 4.22 結果 2



図 4.23 結果 3

図 4.21, 図 4.22 および図 4.23 からわかる通り、左右の 1/3 を検出しないことで先行車のみを検出し、より正しく渋滞推定を行うことができている。また、実験 1 と実験 2 における動画の中で渋滞だと検出した回数の比較の表を以下に示す。

映像番号	実験 1	実験 2
映像 1	425	131
映像 2	1309	401
映像 3	256	59
映像 4	1364	65

表 4.3 実験 2 - 結果

4.11 まとめ

本章では、本研究におけるシステムの実装とシステム改良のための予備実験について述べた。予備実験では使用する深度推定ライブラリの決定、画像圧縮問題の解決および評価基準の決定を行った。次章では本研究における本実験について述べる。

第 5 章

実験

ここでは本研究において行った実験について述べる。

5.1 実験 1 - さまざまな状況における Depth2Jam の推定精度実験

実装と予備実験の項で述べた実験を通して Depth2Jam をさらに改良し、さまざまな状況下のドライブレコーダー映像を使って Depth2Jam の推定精度を測定する実験を行った。これまでの実験に用いたデータセットはどれも前方に先行車があるという状況だったが、この実験では先行車がない映像や信号で停止している映像を用いて Depth2Jam の推定精度に関して実験評価を行う。実験 3 を行うにあたって人間の目で渋滞しているフレーム数を数える必要があるため、Depth2Jam において出力された映像の中央にフレーム数を明記されるように改良した。また、本実験においては人間の目で渋滞を判断するにあたって、信号等の要素を排除し、車間距離が近いと感じられる、あるいは車道において先行車が停止し、停止ランプがついており、ドライブレコーダーが取り付けられている自動車も停車している状況を渋滞と判断し、渋滞だと判断したフレーム数を Ground Truth とした。

5.2 実験 2 - Depth2Jam の精度評価実験

Depth2Jam における再現性、適合率及び mAP 値を測定するための実験を行った。実験にて出力された映像データー 5 つから、それぞれ 20 フレームずつ抽出し、合計 100 フレーム画像において、Depth2Jam の渋滞判断においてさまざまな指標における結果を図 5.3 に示す。表における総合とは、それぞれの映像から合計 20 フレーム画像ずつ抽出し、合計 100 画像となったテストデーターを指す。また、TP, FP, FN, TN のそれぞれの説明および評価指標の説明を以下に示す。

- TP : Depth2Jam が渋滞だと判断し、実際に渋滞しているフレーム
- FP : Depth2Jam が渋滞だと判断したが、実際には渋滞していないフレーム
- FN : Depth2Jam が渋滞ではないと判断したが、実際には渋滞していたフレーム
- TN : Depth2Jam が渋滞でないと判断し、実際に渋滞していないフレーム

加えて、比較対象として、画面全面の自動車類を検出した場合の結果を表 5.4 に示す。

5.2.1 使用したデータセット

本実験において使用したデータセットを以下の表に示す。

映像番号	映像の内容	映像時間	フレーム数	時間帯	道路
映像 1	全く渋滞していない	60 秒	1830 フレーム	昼	一般道
映像 2	先行車あり スムーズに進んでいる	60 秒	1830 フレーム	昼	一般道
映像 3	途中信号による停車あり	60 秒	1830 フレーム	昼	一般道
映像 4	渋滞中の継続的な渋滞	60 秒	1830 フレーム	昼	一般道
映像 5	信号による停車	31 秒	928 フレーム	昼	一般道

表 5.1 実験 データーセット

5.3 実験結果

データセットで述べたドライブレコーダー映像において Depth2Jam が出力した結果および人間の判断の結果を表 5.2 に示す。表 5.2 の通り、映像 1 の結果は先行車がなく、全く渋滞していないドライブレコーダー映像であり、Depth2Jam における出力結果においても渋滞の誤検出はなかった。それに対して、映像 2 においては、先行車ありではあるが止まることなくスムーズに進んでいる自動車のドライブレコーダー映像である。スムーズに進んでいても、4 フレームにおいて渋滞だと誤検出するケースが発生した。映像 3~5 に関してはどの映像においても Ground Truth に対して Depth2Jam における渋滞推定フレーム数は少なくなっている。

映像番号	映像の内容	Depth2Jam の渋滞推定フレーム数 (a)	Ground Truth(b)
映像 1	先行車なし 無渋滞	0	0
映像 2	先行車あり スムーズに進んでいる	4	0
映像 3	途中信号による停車あり	167	870
映像 4	渋滞中の継続的な渋滞	130	452
映像 5	信号による停車	251	927

表 5.2 実験 1 - 結果

映像	TP	FP	FN	TN	正解率 (Accuracy)	適合率 (Precision)	再現率 (Recall)	特異度 (Specificity)	F 値 (F-measure)
映像 1	0	0	0	100	1	0	0	1	0
映像 2	0	0	0	100	1	0	0	1	0
映像 3	7	0	43	50	0.57	1	0.14	1	0.25
映像 4	4	0	29	67	0.71	1	0.12	1	0.22
映像 5	26	0	74	0	0.26	1	0.26	1	0.33
総合	5	0	31	64	0.69	1	0.14	1	0.24

表 5.3 実験 2 結果

映像	TP	FP	FN	TN	正解率 (Accuracy)	適合率 (Precision)	再現率 (Recall)	特異度 (Specificity)	F 値 (F-measure)
映像 1	0	8	0	92	0.92	0	0	0.92	0
映像 2	0	29	0	71	0.71	0	0	0.71	0
映像 3	10	5	43	42	0.52	0.33	0.19	0.89	0.24
映像 4	7	15	29	49	0.56	0.32	0.19	0.77	0.24
映像 5	69	0	31	0	0.69	1	0.69	0	0.82
総合	11	10	15	64	0.75	0.52	0.42	0.86	0.46

表 5.4 (参考) 画面全体を検出した場合の精度

5.4 評価

本研究では、実装したシステムの精度を評価するにあたって F 値を用いた。F 値とは、再現率と適合率の調和平均の値であり、渋滞している/していないのような混合行列となるシステムの評価に適しているものである。表 5.3 の表の通り、映像 1 および映像 2 において渋滞していると判断できるフレームは存在しないので F 値は 0 となっているが、映像 3 5 及び総合フレームにおいては 0.22 0.33 という結果になった。正解率をみると 0.26 1 とばらつきがあるものの、F 値が 0.2 付近にあるため、現段階の Depth2Jam の渋滞推定精度はまだ実用化には遠く、性能向上が必要であると評価される。

第 6 章

考察

ここでは本研究が行った実験とその評価についての考察を述べる。

6.1 精度の考察

画面全体を検出した場合の表表 5.4 と表 5.3 を比較する。2 つの表を比較した際に、大きな違いは FP である。実装した Depth2Jam は画面中央部分のみを検出するように改良したため FP がどの動画においても 0 という結果になっているが、画面全体を検出する場合では FP が最大で 29 まで増加している。画面両端の 1/3 部分を検出しないようにした結果、Depth2Jam の正確性が向上したことがこの比較でわかる。次に、映像 5 における 2 つの結果を比較した際に、表 5.4 においては F 値が 0.82 と表 5.3 における F 値の 0.33 より大幅に上昇している。

6.1.1 誤検出

まず、5.1 における誤検出の例とその原因についての考察を述べる。表 5.2 において、映像 1 においては誤推定されたフレームは存在しないが、映像 2 においては渋滞ではないのに渋滞だと誤推定されたフレームが存在する。誤推定されたフレームの例を図 6.1 と図 6.2 に示す。

どちらのフレーム画像においても検出された自動車が中央に寄っており、かつ検出された BBOX における平均 G 値が 100 を超えてしまっているので渋滞だと判断してしまっていることがわかる。実装した Depth2Jam システムにおいては、画面左右 1/3 における自動車の検出がされないようにしているが、この検出除外処理は、検出された BBOX における 2 つの X 軸の値のうち、左側つまり小さい方の値の X 軸が画面の左右 1/3 の範囲に含まれる場合に発生する。このフレームではその X 軸の値が中央 1/3 の範囲に含まれているためこのような結果になったのだと思われる。より精度を向上させるために、BBOX における X 軸の値のうち、右側つまり値の大きい方の X 軸に対しても追加で検出除外処理を設ける必要があると考えられる。

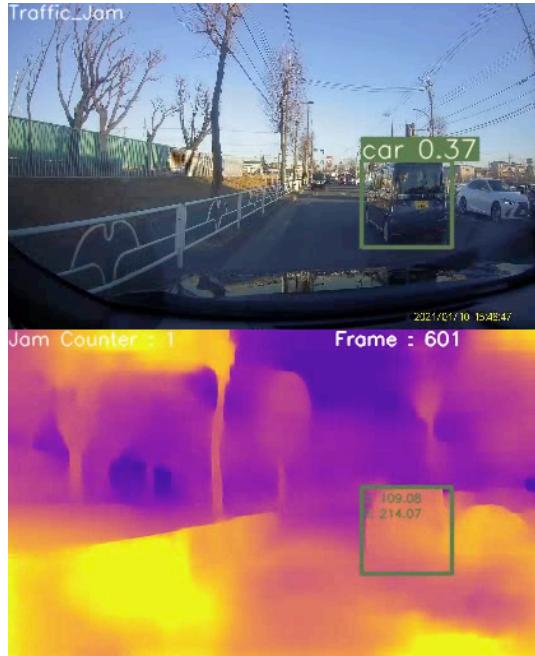


図 6.1 誤検出の例 1

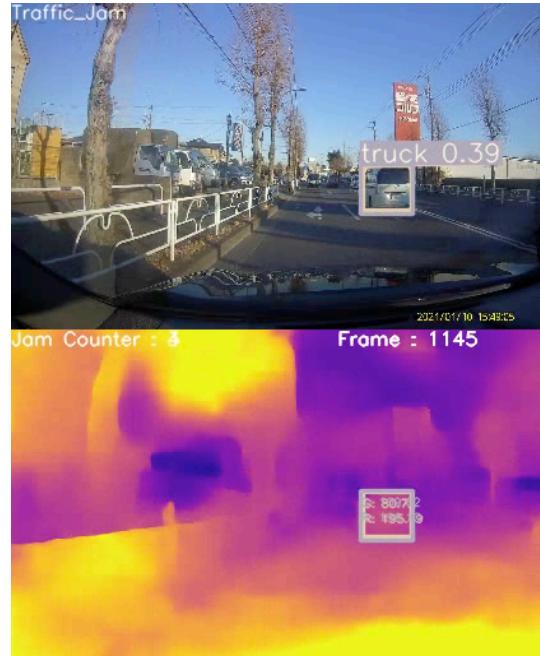


図 6.2 誤検出の例 2

6.1.2 FN に関する考察

ここでは、表 5.3 における FN に関する考察について述べる。映像 1 と映像 2 に関しては渋滞しているフレームは存在しないので FN の値も 0 となっているが、映像 3 5 および総合においては FN の値が目立つ。FN はシステムが渋滞でないと判断したが、実際には渋滞していたフレームであり、現実では信号や渋滞等で自動車が動いていないのにシステムが渋滞だと判断できていなかったフレームである。そのフレームの例を図 6.3 と図 6.4 に示す。

どちらの例も先行車が停車しており、ドライブレコーダーを搭載した自動車も停車している状況である。そして、検出された BBOX において、G 値の値は 70 程度となっており、渋滞と判断されていない。考えられる原因としてはドライバーが車間距離に余裕を持って停車しているため、G 値が相対的に小さくなってしまっていることにあると考えられる。車間距離に余裕を持って停車することは本来推奨される運転のため、余裕を持って車間距離をとっている場合でも渋滞だと推定できる手法を取る必要がある。



図 6.3 FN の例 1



図 6.4 FN の例 2

第 7 章

結論

ここでは、本研究における今後の展望と本研究のまとめについて述べる。

7.1 今後の展望

実験を通じて、ドライブレコーダーを使用することで渋滞を推定することが可能であることがわかった。しかし、渋滞推定システムが実用化されるにはいくつか解決しなければならない問題がある。

7.1.1 処理時間の問題

課題のひとつに処理にかかる時間という問題がある。現状のシステムはあらかじめ用意されたドライブレコーダー映像を処理しているが、Depth2Jam が実用化されるためにはリアルタイムで映像処理ができる必要がある。しかし、現状のシステムでは 1 分の動画を処理するのに 10 分程度かかる。

処理時間の減少を図る方法はいくつか考えられる。まず、処理する量を減らす手法である。現状のシステムでは深度推定ライブラリと物体検出ライブラリの実行を全ての映像のフレームで行っている。この処理において、先に物体検出ライブラリで自動車類を検出し、検出できたフレームだけ深度推定ライブラリを実行するという方法である。深度推定ライブラリを実行する回数を減らすことで総合的な処理時間を減少することが可能なのではないかと考えられる。

7.1.2 容量の問題

加えて車に搭載するには必要な容量が膨大である問題がある。現状のシステムは TensorFlow ライブラリと PyTorch ライブラリの両方を利用しているため、実際に自動車に搭載してリアルタイムで検出するにはそれぞれのライブラリが入るほどの記憶容量が必要である。しかし、現状の Nvidia Jetson といった開発向けの GPU 装置は TensorFlow ライブラリと PyTorch ライブラリの両方を保存できるだけの容量の余裕がない。この問題を解決する方法の一つとして使用するライブラリを TensorFlow か PyTorch のどちらか一方に絞るという方法がある。Tensorflow もしくは PyTorch のどちらかに絞ることができれば容量削減と同時に呼び出すライブラリを減らすことができ、処理時間を減らすことが期待できる。

7.2 本研究のまとめ

本研究では新たな渋滞推定手法としてドライブレコーダー及び深度推定ライブラリ, 物体検出ライブラリを用いた渋滞推定システム Depth2Jam についての提案を行った. 深度推定ライブラリを用いることでカメラからの距離を推量することが可能であり, 物体検出ライブラリを用いることで推量したい物体を検出することが可能である. 実験では実際にドライブレコーダー映像をもとに Depth2Jam を用いて実証実験を行い, 渋滞を推定できているか評価を行った. 評価実験においては評価指標に F 値を用いた結果 2 割程度だった. 渋滞を正しく分類する精度はまだまだはあるが, さまざまな改善をすることにより精度向上が期待される.

謝辞

本研究を進めるにあたり、ご指導を頂きました慶應義塾大学環境情報学部教授中澤仁博士に深く感謝いたします。また、慶應義塾大学中澤研究室の諸先輩方には折に触れ貴重なご助言を頂きました。特に慶應義塾大学大学院政策・メディア研究科陳寅特任助教、慶應義塾大学大学院政策・メディア研究科大越匡特任講師には本論文を執筆するにあたってご指導頂きました。ここに深く感謝の意を表します。そして、慶應義塾大学大学院大学院政策・メディア研究科研究員伊藤友隆氏、慶應義塾大学大学院博士課程 佐々木航氏、慶應義塾大学大学院博士課程 磯川直大氏、慶應義塾大学大学院修士課程 本木悠介氏、慶應義塾大学大学院修士課程 小澤遼氏、慶應義塾大学大学院修士課程 安井慎一郎氏には本研究に対し多くの時間を割いていただきご指導をいただきました。佐々木航氏には、レインボーシックスシージを通じてさまざまな戦術を披露していただき、とても参考になりました。安井慎一郎氏には卒論執筆に際してアドバイスをいただきたり、激励いただきたり、バーミヤンを奢っていただきました。伊藤友隆氏には中華料理などの食事に連れていいただきました。小澤遼氏には研究室における作業スペースが隣だったこともあり、TERM や卒論で励ましていただきました。ここに感謝致します。

陰から研究活動を支えて頂いた、松尾さん、遠藤さんに深く感謝申し上げます。そして、私のメンターである慶應義塾大学大学院修士課程 柿野優衣氏に深く感謝致します。柿野氏には WIP の時からお世話になりました。特に TERM の時期には意見が噛み合わなかったり、発表前日に発表スライドを大幅に変えてしまったりと大変なご迷惑をおかけしました。そして同じ研究室の先輩方の、慶應義塾大学大学院修士課程 谷村朋樹氏、慶應義塾大学大学院修士課程 川島寛乃氏、慶應義塾大学大学院修士課程 山田佑亮氏に深く感謝致します。

また研究室の同期として、研究活動に切磋琢磨した野田悠加氏、スウィート哲也キース氏、橘直雪氏、マンタタ・タガツオ・ウイリアム氏、助川友里氏、菅原メリッサ紗良氏、鈴木航平氏、山根卓氏に感謝致します。そして、違う分野ながらもお互いに卒論の執筆について切磋琢磨し、同時に私の精神面を支えてくださった彼女氏に深く感謝致します。また、私がブレイクダンスをやらなくなってしまってからも、積極的にダーツ等の遊びに誘っていただいた友人の岩間大輝氏に深く感謝致します。

最後に両親へ心から深く感謝を述べます。前大学での1年半の学費及び生活費を支援してくれたにもかかわらず、中退してしまったことをこの場を借りて改めて謝罪します。一度中退してしまった私に、半年の海外語学留学と、1年間の北九州予備校での浪人というチャンスをいただき、慶應義塾大学の塾生となることができました。ここに深く感謝します。

2020年1月21日

李 広耀

参考文献

- [1] 国土交通省 自動車局保障制度参事官室. 国土交通行政インターネットモニターインケート 自動車用の映像記録型 ドライブレコーダー装置について, 2020. <https://www.mlit.go.jp/monitor/R1-kadai01/24.pdf>.
- [2] Vincent Casser, Soeren Pirk, Reza Mahjourian, and Anelia Angelova. Depth prediction without the sensors: Leveraging structure for unsupervised learning from monocular videos. In *Thirty-Third AAAI Conference on Artificial Intelligence (AAAI-19)*, 2019.
- [3] Joseph Redmon and Ali Farhadi. Yolov3: An incremental improvement. *arXiv*, 2018.
- [4] Vics. <https://www.vics.or.jp/>.
- [5] 道路交通情報ビジネスの現状と今後の展望 – 中間取りまとめ –, 2001. <http://www.npa.go.jp/bureau/traffic/seibi2/shinsei-todokede/jouhou/tyukanntorimatome.pdf>.
- [6] くるまニュース編集部. ドライブレコーダーの普及率は4割強！装着理由の大半は「トラブルの防止」. <https://kuruma-news.jp/post/302898>, 2020.
- [7] マイボイスコム. <https://www.myvoice.co.jp/index.html>.
- [8] 国土交通省. 観光地における渋滞対策. <https://www.mlit.go.jp/common/001150187.pdf>.
- [9] 国土交通省. I C T・A I を活用したエリア観光渋滞対策について. https://www.mlit.go.jp/road/ir/ir-council/keizai_senryaku/pdf07/3.pdf.
- [10] 三上量弘, 陳寅, 中澤仁ほか. Deepcounter: 深層学習を用いた細粒度なゴミ排出量データ収集手法. 情報処理学会論文誌, Vol. 61, No. 1, pp. 36–48, 2020.
- [11] CEATEC. Japantaxi, タクシーの価値活かすリアルタイムデータ情報で多業種と連携へ. <https://www.ceatec.com/news/ja-webmagazine/074>, 2019.
- [12] 渋滞の定義とは. 高速道路の渋滞原因は先頭？渋滞回避やハザードなどの事故対策, 2020. <https://www.zurich.co.jp/car/useful/guide/cc-whatis-definite-trafficjam/>.
- [13] 高速道路の渋滞対策, 2018. https://www.e-nexco.co.jp/activity/safety/detail_07.html.
- [14] 交通渋滞中のドライバーの精神的ストレスおよび肉体的ストレスに対する芳香物質の影響: パイロットスタディ. コスマトロジー研究報告 [[コスマトロジーケンキュウホウコク]], Vol. 22, .
- [15] 社会資本整備審議会 道路分科会国土幹線道路部会. 高速道路を中心とした「道路を賢く使う取組」の基本方針, 2015. <https://www.mlit.go.jp/common/001066982.pdf>.
- [16] 塩澤誠一郎. 自動運転は年間約10兆円の経済損失をプラスの経済効果に変えることができるか? <https://www.nli-research.co.jp/report/detail/id=63430?site=nli>, 2020.
- [17] Waze. <https://www.waze.com/>.
- [18] Sigic. <https://www.sigic.com/>.

- [19] Google. Google ポリシーと規約. <https://policies.google.com/technologies/location-data?hl=ja#how-find>.
- [20] Ben Schoon. Google maps ‘hack’ uses 99 smartphones to create virtual traffic jams. 9to5google, 2020. <https://9to5google.com/2020/02/04/google-maps-hack-virtual-traffic-jam/>.
- [21] 全邦釤, 嶋本ゆり, 大窪和明, 三輪知寛, 大賀水田生. ディープラーニングおよび random forest によるコンクリートのひび割れ自動検出手法. 土木学会論文集 F3 (土木情報学), Vol. 73, No. 2, pp. I_297–I_307, 2017.
- [22] 進藤瞭, 白石陽ほか. 車載カメラ画像を用いた対向車線の渋滞状況の把握手法. マルチメディア, 分散協調とモバイルシンポジウム 2013 論文集, Vol. 2013, pp. 139–146, 2013.
- [23] Tinghui Zhou, Matthew Brown, Noah Snavely, and David G Lowe. Unsupervised learning of depth and ego-motion from video. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1851–1858, 2017.
- [24] Zhichao Yin and Jianping Shi. Geonet: Unsupervised learning of dense depth, optical flow and camera pose. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1983–1992, 2018.
- [25] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. In *Advances in neural information processing systems*, pp. 91–99, 2015.
- [26] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision*, pp. 2961–2969, 2017.
- [27] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C Berg. Ssd: Single shot multibox detector. In *European conference on computer vision*, pp. 21–37. Springer, 2016.
- [28] Iro Laina, Christian Rupprecht, Vasileios Belagiannis, Federico Tombari, and Nassir Navab. Deeper depth prediction with fully convolutional residual networks. In *3D Vision (3DV), 2016 Fourth International Conference on*, pp. 239–248. IEEE, 2016.
- [29] 藤田竜太. 100km/h で 100m は空けすぎ？ 安全かつ現実的な車間距離とはどのぐらいか. <https://www.webcartop.jp/2017/09/147023/>.
- [30] 安全のススメ. https://www.toyota.co.jp/mobilitas/anzen/vol29_2.html.